

目 录

1	摘要.....	1
2	关键词.....	1
3	前言.....	2
4	相关理论与技术基础.....	3
4.1	基于 CNN-LSTM 的时空预测模型.....	3
4.2	模型优化策略.....	3
4.2.1	加权 MSE 与 SSIM 联合损失.....	3
4.2.2	学习率预热与余弦退火.....	4
4.2.3	梯度累积与裁剪.....	4
4.2.4	混合精度训练（AMP）.....	4
4.3	面向 RTX 4060 8G 的硬件适配策略.....	4
4.3.1	检查点与早停机制.....	4
4.3.2	显存优化.....	5
4.3.3	数据加载优化.....	5

5 系统设计与实现.....6

5.1 数据预处理与增强.....6

5.2 模型架构.....7

5.3 训练流程与超参数.....9

5.4 评估指标与可视化.....11

6 实验结果与分析.....12

6.1 数据分布分析.....12

6.2 模型训练过程分析.....12

6.3 多阈值 CSI 评估与优化.....13

6.4 可视化结果分析.....14

7 结论与展望.....15

使用 CNN-LSTM 混合架构实现雷达回波外推

古子彦

南京信息工程大学人工智能学院

1 摘要:

雷达回波外推是短时临近预报的关键技术之一，本文基于 CNN-LSTM 混合架构，构建了雷达回波序列预测模型。针对传统 MSE 损失对高值回波预测不足、单一阈值评估不全面等问题，提出加权 MSE 与 SSIM 联合损失，引入多阈值 CSI 评估体系。实验在 RTX4060 8G 显卡上进行，通过梯度累积、混合精度、学习率预热与余弦退火、早停与检查点等优化策略，在 981 个样本的数据集上成功训练。实验结果表明，模型在建议阈值 0.184 下 CSI 达 0.5606，高阈值 0.3 下 CSI 达 0.1614，SSIM 达 0.7562，有效实现了雷达回波的外推预测，验证了优化方案的有效性。

2 关键词:

雷达回波外推；CNN-LSTM；加权损失；多阈值 CSI；混合精度训练

3. 前言

雷达回波外推是指利用历史雷达图像序列预测未来雷达回波的运动趋势，在气象短时临近预报中具有重要应用价值。传统的数值预报方法计算成本高，而基于深度学习的时空预测模型凭借强大的非线性拟合能力，逐渐成为研究热点。

本文以某地区雷达回波数据为研究对象，构建了 CNN-LSTM 混合模型，通过编码器提取空间特征，LSTM 捕获时间依赖，解码器重构未来图像。在训练过程中，针对 MSE 损失对高值回波不敏感的问题，设计了加权 MSE 与 SSIM 联合损失函数；针对评估指标单一的问题，引入多阈值 CSI（关键成功指数），根据数据分布动态调整阈值。同时，结合硬件条件，采用混合精度训练、梯度累积、学习率预热与余弦退火、早停与检查点等策略，实现了高效、稳定的模型训练。

实验环境为 AMD Ryzen AI 9 HX 370 处理器，NVIDIA GeForce RTX 4060 8G 显卡，32GB 内存。数据集包含 943 个样本，每个样本由 20 帧 256×256 灰度图像组成，时间分辨率 5 分钟。输入前 10 帧，预测后 10 帧。最终模型在验证集上达到良好性能，为后续业务部署奠定了基础。

4. 相关理论与技术基础

4.1 基于 CNN-LSTM 的时空预测模型

雷达回波外推本质是一个时空序列预测问题，即给定历史帧序列预测未来帧序列。传统的循环神经网络（RNN）能够处理时间依赖，但对高维图像空间结构建模能力不足；卷积神经网络（CNN）擅长提取局部空间特征，但无法直接处理时序。CNN-LSTM 混合架构将两者结合，利用 CNN 编码器将每一帧图像压缩为特征向量，再输入 LSTM 进行时序建模，最后通过解码器重构图像。

编码器由多个卷积层和池化层堆叠而成，逐步提取高层语义特征，同时降采样减少计算量。本文采用三层卷积（通道数 $64 \rightarrow 128 \rightarrow 256$ ），每层后跟 ReLU 激活和 2×2 最大池化，最终将 256×256 图像压缩为 $32 \times 32 \times 256$ 的特征图。

时序建模采用 LSTM（长短期记忆网络），它通过输入门、遗忘门和输出门控制信息流动，能够有效捕获长期依赖，避免梯度消失。将编码后的特征向量展平，通过全连接层压缩至隐层维度（HIDDEN_DIM=512），输入 LSTM 进行序列建模。解码器使用转置卷积（反卷积）将特征图上采样回原图尺寸，并采用 Sigmoid 激活将输出约束在 $[0, 1]$ 区间，与输入值域一致。

4.2 模型优化策略

4.2.1 加权 MSE 与 SSIM 联合损失

传统的均方误差（MSE）对所有像素一视同仁，在雷达回波预测中，背景像素占比远大于强回波区域，导致模型偏向优化背景，高值区域预测模糊。为此，我们设计了加权 MSE：

$$MSE_{weighted} = \frac{1}{N} \sum_i (1 + \alpha \cdot y_i) \cdot (p_i - y_i)^2$$

其中 y_i 为真实像素值， α 为权重系数（本文取 5），使高值像素获得更大梯度，引导模型关注强回波。

同时，引入结构相似性（SSIM）损失，其定义为：

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

SSIM 值越接近 1 表示图像越相似。我们将 SSIM 损失定义为 $1 - SSIM$ ，并与加权 MSE 线性组合：

$$\mathcal{L} = \text{MSE}_{\text{weighted}} + \lambda(1 - \text{SSIM})$$

本文取 $\lambda = 0.1$ ，平衡两项贡献。

4.2.2 学习率预热与余弦退火

学习率调度对训练稳定性至关重要。在训练初期，模型参数随机，过大的学习率可能导致振荡；随着训练进行，需要逐渐降低学习率以精细调参。本文采用预热+余弦退火策略：

(1) 预热阶段（前 5 个 epoch）：学习率从 0 线性增长至初始学习率（ $1e-3$ ）。

(2) 余弦退火阶段：学习率按余弦函数从初始值衰减至 0：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos\left(\frac{T_{\text{cur}}}{T_{\max}}\pi\right)\right)$$

(1) 该策略可帮助模型平稳收敛，并避免陷入局部极小值。

4.2.3 梯度累积与裁剪

由于 RTX4060 显存为 8G，无法直接使用大批量训练。梯度累积技术通过多次前向传播后才更新参数，模拟大批量效果。设微批次大小为 b ，累积步数为 s ，则有效批次为 $b \times s$ 。本文设置 $b = 4$ ， $s = 4$ ，有效批次为 16。

为防止梯度爆炸，使用梯度裁剪，将梯度范数限制在 1.0 以内。

4.2.4 混合精度训练（AMP）

混合精度训练使用半精度浮点数（FP16）进行前向和反向传播，减少显存占用并加速计算。NVIDIA Tensor Core 可显著提升 FP16 运算效率。本文采用 PyTorch 的 `torch.cuda.amp` 模块，配合梯度缩放（GradScaler）防止下溢。

4.3 面向 RTX 4060 8G 的硬件适配策略

4.3.1 检查点与早停机制

为充分利用硬件资源，我们设计了检查点（checkpoint）机制，每 5 个 epoch 保存一次模型状态（包括模型参数、优化器状态、学习率调度器状态、混合精度缩放器状态），以便在训练中断后从最新检查点恢复，避免重复训练。

同时采用早停（early stopping）防止过拟合，当验证损失连续 10 个 epoch 未下降时终止训练，并加载历史最佳模型。早停不仅节省时间，还能自动选择最优模型。

4.3.2 显存优化

(1) 逐批次指标计算：验证时，对每个批次计算指标并累加，避免存储整个验证集的预测结果，降低显存峰值。

(2) `drop_last`：数据加载时丢弃最后一个不完整批次，保证梯度累积时批次大小一致，避免显存碎片。

(3) `torch.cuda.empty_cache()`：每个 epoch 结束后手动释放未使用的缓存，保持显存清洁。

4.3.3 数据加载优化

利用多进程数据加载 (`num_workers=4`) 和锁页内存 (`pin_memory=True`)，减少 CPU 与 GPU 间的数据搬运延迟。

5. 系统设计与实现

5.1 数据预处理与增强

原始数据包含 943 个样本，每个样本对应 20 张 PNG 图像，文件名在 CSV 中记录（如 00001.png），实际存储为 radar_00001.png。数据预处理流程如下：

（1）文件验证：遍历 CSV，检查每个样本所需的 20 张图像是否存在，构建有效索引列表。

（2）图像读取与变换：

①调整尺寸至 256×256 。

②转换为 Tensor，值域归一化至 $[0, 1]$ 。

③训练集增强：随机水平翻转（ $p=0.5$ ）。经实验发现，随机旋转（5 度）会破坏回波运动物理规律，导致 CSI 下降，因此取消该增强。

（3）划分数据集：按 80:20 比例划分训练集和验证集，确保样本不重叠。

数据分布分析如图 1 显示，真实值均值 0.1826，中位数 0.1176，75%分位数 0.1843，90%分位数 0.3922，说明强回波稀疏且集中在较高值。




图 1

5.2 模型架构

模型结构如图 2 所示，具体参数：

编码器：Conv2d(1, 64, 3, 1, 1) $\rightarrow$ MaxPool2d(2) $\rightarrow$ Conv2d(64, 128, 3, 1, 1) $\rightarrow$ MaxPool2d(2) $\rightarrow$ Conv2d(128, 256, 3, 1, 1) $\rightarrow$ MaxPool2d(2)

特征压缩：Linear($256 \times 32 \times 32$, 512)

LSTM：输入 512，隐层 512，批优先

特征解压：Linear(512, $256 \times 32 \times 32$)

解码器：ConvTranspose2d(256, 128, 4, 2, 1) $\rightarrow$ ConvTranspose2d(128, 64, 4, 2, 1) $\rightarrow$ ConvTranspose2d(64, 1, 4, 2, 1) $\rightarrow$ Sigmoid

总参数量约 2.72 亿。




图 2

5.3 训练流程与超参数

训练流程如图 3 所示，主要超参数如表 1：

参数	值
有效批次大小	16
初始学习率	1e-3
预热轮数	5
最大轮数	100
权重衰减	1e-5
梯度裁剪范数	1.0
加权 MSE 系数	5
SSIM 损失权重	0.1

表 1




图 3

优化器采用 Adam，学习率调度使用自定义 LambdaLR。

5.4 评估指标与可视化

评估指标包括：

- (1) MSE：均方误差
- (2) MAE：平均绝对误差
- (3) SSIM：结构相似性（使用 `torchmetrics` 库）
- (4) CSI(τ)：关键成功指数，对预测和真实进行阈值 τ 二值化后计算 Jaccard 指数。

其中阈值 τ 根据数据分布设定为 $[0.1, 0.15, 0.184, 0.2, 0.25, 0.3]$ ，以评估不同强度回波的预测效果。

可视化采用叠加图：红色通道显示目标，绿色通道显示预测，重叠区域呈现黄色，直观反映预测准确性。

6. 实验结果与分析

6.1 数据分布分析

首先对验证集真实值进行统计分析，结果如图 4 所示。从直方图可以看出，大部分像素集中在 0.1 附近，高值像素 (>0.3) 占比不足 5%。这一分布解释了为何初始阈值 0.5 下 CSI 为 0：模型输出很难达到如此高的值。基于此，我们将阈值调整为 0.184（75%分位数）作为主要参考，并增加多阈值评估。




图 4

6.2 模型训练过程分析

训练共进行 25 轮，在第 14 轮验证损失达到最低 0.0080，之后波动并触发早停。训练损失和验证损失曲线如图 5 所示，两者均稳步下降且未出现显著偏离，表明模型未过拟合。SSIM 从 0.688 提升至 0.756，说明预测图像结构逐渐接近真实。CSI 指标随训练动态变化：在低阈值 0.1 下 CSI 接近 1.0（几乎所有像素超过阈值）；在 0.184 阈值下 CSI 稳定在 0.5~0.56；高阈值 0.3 下 CSI 由 0.027 提升至 0.16，表明模型学会了部分强回波区域。




图 5

6.3 多阈值 CSI 评估与优化

初始实验中，固定阈值 0.5 导致 CSI 为 0，无法衡量模型进步。通过分析数据分布，我们将阈值调整为数据 75%分位数 0.184，并增加 0.1、0.15、0.2、0.25、0.3 等梯度阈值，形成多维度评估体系。这一改变使得训练过程能够直观反映模型在不同回波强度上的表现，便于针对性地调整损失函数。

同时，实验发现随机旋转增强会降低 CSI（尤其是高阈值），因此取消该增强，仅保留水平翻转，提升了模型鲁棒性。

最终模型在验证集上的指标如表 1 所示。

指标	值
MSE	0.0080
MAE	0.0566
SSIM	0.7562
CSI@0.1	1.0000
CSI@0.15	0.4994
CSI@0.184	0.5606
CSI@0.2	0.5391
CSI@0.25	0.4184
CSI@0.3	0.1614

表 2

6.4 可视化结果分析

图 6 展示了四个测试样本的预测效果，每行依次为最后一帧输入、目标与预测叠加（第 1、6、10 帧）。从叠加图可以看出：

（1）低阈值回波区域（如背景噪声）基本被预测覆盖（绿色多），但真实目标区域（红色）大多与绿色重叠形成黄色，说明位置准确。

（2）高阈值回波区域（图中亮红部分）预测绿色略有缺失，但整体形态保持较好，部分区域命中。

（3）通过可视化，可以直观验证模型在强回波区域的预测能力，为后续改进提供依据。




图 6

7. 结论与展望

本文基于 CNN-LSTM 架构，通过加权 MSE 与 SSIM 联合损失、多阈值 CSI 评估、混合精度训练、梯度累积等优化策略，成功训练了雷达回波外推模型。实验结果表明，模型在数据驱动的时空预测任务中表现良好，能够有效捕捉回波运动规律，在高阈值（0.3）下仍能达到 0.16 的 CSI，验证了优化方案的有效性。

未来工作可从以下方向展开：

- （1）引入更先进的时空预测模型（如 ConvLSTM、PredRNN），进一步提升时序建模能力。
- （2）采用注意力机制，增强模型对关键区域的关注。
- （3）探索生成对抗网络（GAN）以提升预测清晰度。